Nutq matni

«O‘zbek tili gaplarini neyron tarmoqlar asosida sintaktik tahlil qilishning matematik modeli»

Ma’ruzachi: S. Matlatipov

19 ta slayd · 15 daqiqa

Qanday o‘qiladi

- Matn qisqa, sodda gaplardan iborat — shoshilmasdan o‘qing (daqiqasiga taxminan 90 so‘z).
- Formulalar va raqamlar slaydda ko‘rinib turadi; ularni to‘liq o‘qish shart emas.
- **qalin matn** — urg‘u bilan aytiladi; **[pauza]** — ikki-uch soniya to‘xtang; *[Ko‘rsating: . . .]* — ekrandagi joyga ishora qiling.
- Vaqt yetmasa, 3- va 16-slaydlarni qisqartiring (har biri 20 soniyagacha).

Vaqt nazorati (har bir bo‘limga shu vaqtda yetib keling)

Bo‘lim	Slaydlar	Boshlanish
Kirish: dolzarblik, masala, maqsad, yangilik	1–6	0:00
Matematik model	7–10	5:00
Sonli usullar	11–12	8:25
Tajribalar va natijalar	13–15	10:20
Dasturiy majmua, xulosa, aprobatsiya	16–19	13:05

Mavzu nomi bo‘yicha muqobil variantlar (ilmiy rahbar bilan kelishing)

1. *(slaydlarda)* «O‘zbek tili gaplarini neyron tarmoqlar asosida sintaktik tahlil qilishning matematik modeli».
2. «Kam resursli o‘zbek tili uchun morfosintaktik tahlilning graf-ehtimollik modeli».
3. «O‘zbek tili gaplarini bog‘liqlik sintaksisi asosida tahlil qilishning matematik modellari, algoritmlari va dasturiy majmuasi».

«Semantik» so‘zini nomga kiritmang: semantik qatlam annotatsiya qilinmagan va baholanmagan.

Savollar uchun asosiy raqamlar (ma'ruzada aytish shart emas)

UzUDT	684 gap, 7 582 token; 6 annotator; Cohen κ: lemma 95,2 %, UPOS 93,7 %, belgilar 90,8 %; UD v2.17, validatsiyadan o‘tgan
UT	500 gap, 5 930 token; UD validatsiyasi: 92 ogohlantirish
Bo‘linmalar	UzUDT tajribalari (.1): 435 / 48 / 198 gap; birlashma (.2): 781 / 78 / 325 gap
Korpus statistikasi	noproyektiv gaplar 9,2 % (UzUDT 11,0 %, UT 6,8 %); hokim o‘ngda 84,6 %; o‘rtacha yoy 2,72; qo‘shni so‘zlar orasidagi yoylar 52 %; munosabat turlari 39
Model	TahrirchiBERT: 12 qatlam, 768, BPE lug‘ati 30 528; $\mathbf{v}_i \in \mathbb{R}^{1143}$; BiLSTM $3 \times (2 \times 400)$; bi-affin 400; teglovchi $2 \times (2 \times 200)$
O‘qitish	Adam (0,9; 0,95), $\alpha = 3 \cdot 10^{-3}$, $\varepsilon = 10^{-6}$, $\|g\| \le 1$, dropout 0,5, partiya 5 000 token; 3 000 qadam sabr $\rightarrow$ AMSGrad; eng yaxshi qadam 800–1 300
Validatsiya (LAS)	E1.1 55,28; E2.1 **58,23**; E3.1 55,90; E1.2 62,87; E2.2 **63,81**
Validatsiya (UPOS)	E1.1 79,19; E2.1 83,54; E3.1 83,39; E1.2 83,78; E2.2 87,19
Bootstrap	oxirgi–o‘rtacha: ΔLAS = +2,64, 95 % IO [0,97; 4,12], $p \approx 0{,}002$
Test (198 gap)	Stanza E2.1: UAS 71,06, LAS 54,07; spaCy S1.1: UAS 67,72, LAS 45,35
G‘alayonlar (ΔLAS)	diakritika −1,14; kod almashuvi −0,14; bosh harf −2,52; tinish belgisiz −8,30

Seminardan oldin tekshiring (repozitoriy va jurnallar tahlili natijalari)

1. Titul slayddagi **ilmiy rahbar** (prof. M. M. Aripov deb olindi) va kafedra nomini tasdiqlang (`\ilmiyrahbar` buyrug‘i).

2. **Muhim.** Maqolalardagi «test» jadvali aslida **validatsiya** natijalari: `*_summary.json` dagi `final_uas/final_las` — dev faylining oxirgi qadamdagi qiymati (E2.2 uchun — eng yaxshi qadam). Taqdimotda raqamlar «validatsiya, eng yaxshi nazorat nuqtasi» deb to‘g‘ri belgilangan.

3. **Muhim.** Birlashma (.2) tajribalarida parserga **oltin** UPOS/XPOS/UFeats berilgan (`data/depparse/merged` fayllari), UzUDT (.1) tajribalarida esa eski XLM-R teglovchisining bashorati. Shuning uchun maqoladagi «korpuslarni birlashtirish LAS ni 9,6–11,2 punkt oshiradi» xulosasi bu jurnallar bilan tasdiqlanmaydi.

4. .1 va .2 da UzUDT ning **turli bo‘linmalari**: 435 / 48 / 198 (eski) va 451 / 45 / 188 (yangi); eski dev ning 38 gapi yangi train ichida.

5. Birlashtirilgan fayllarda kodlash xatosi: «o‘yinni» → «oÊ»yinni» (train da 2 554 marta).

6. E3.2 raqamlari (84,02 / 87,07 / 70,39 / 70,74 / 60,05) jurnallarda topilmadi: teglovchi jurnali 1 500-qadamda tugagan, parser jurnali yo‘q.

7. TahrirchiBERT — bayt darajasidagi **BPE** tokenizator (WordPiece emas); «bola ##lar ##ning» misoli haqiqiy emas (haqiqatda *bolalarning* — bitta token).

8. Haqiqiy giperparametrlar (W&B): $\beta_2 = 0{,}95$, dropout 0,5 (so‘z dropout 0,33), bi-affin 400, BiLSTM 3×400; maqolada $\beta_2 = 0{,}999$, dropout 0,33, MLP 500. BERT qatlamlari: kodda $(\mathbf{H}^{(9)} + \mathbf{H}^{(10)} + \mathbf{H}^{(11)})/4$.

9. Munosabat turlari: 39 (maqolada 41). Robustlik jurnalidagi UPOS/UFeats raqamlari oltin teglarga nisbatan emas — taqdimotda faqat UAS/LAS ishlatildi.

1-slayd — Titul varag‘i

[0:00 → 0:35]

Hurmatli kafedra mudiri! Hurmatli seminar ishtirokchilari!

Sizlarga **«O‘zbek tili gaplarini neyron tarmoqlar asosida sintaktik tahlil qilishning matematik modeli»** mavzusidagi tadqiqotimni taqdim etaman. Ish matematik modellashtirish, sonli usullar va dasturlar majmui ixtisosligi bo‘yicha bajarilmoqda.

Asosiy g‘oyam: gapning sintaktik tuzilishini aniqlash — bu **graf ustidagi optimallashtirish masalasi**. Uni ehtimollik modeli va aniq sonli algoritm bilan yechish mumkin.

2-slayd — Mavzuning dolzarbligi

[0:35 → 1:35]

O‘zbek tili — **agglyutinativ til**. So‘zga qo‘shimchalar ketma-ket qo‘shiladi va har biri grammatik ma’no tashiydi.

[Ko‘rsating: «kitoblarimizdagi» sxemasi]

Masalan, «kitoblarimizdagi» so‘zida o‘zak va to‘rtta qo‘shimcha bor. Neyron til modeli esa uni «kitob», «larimiz», «dagi» bo‘laklariga ajratadi. Eng muhim grammatik ma’lumot — **oxirgi bo‘lakda**.

[Ko‘rsating: diagramma]

Ikkinchi muammo — ma’lumot kamligi. Universal Dependencies tizimida o‘zbek tili uchun bor-yo‘g‘i **bir ming bir yuz sakson to‘rtta** gap an-

notatsiyalangan. Turk tilida — qariyb o‘n ming, ingliz tilida — o‘n olti mingdan ortiq.

Demak, kichik tanlanmada ham ishonchli ishlaydigan, **matematik asoslangan** model va sonli usullar zarur.

3-slayd — Muammoning o‘rganilganlik darajasi

[1:35 → 2:25]

[Ko‘rsating: vaqt chizig‘i]

Vaqt chizig‘ida sohaning asosiy bosqichlari ko‘rsatilgan: Tesnièrening bog‘liqlik grammatikasidan, Chu–Liu va Edmondsning optimal daraxt algoritmidan boshlab, LSTM, bi-affin parser va BERT modellarigacha. So‘nggi yillarda o‘zbek tili uchun ham TahrirchiBERT modeli va birinchi UD korpusi yaratildi.

[Ko‘rsating: qizil blok]

Biroq uchta masala ochiq qolgan: korpuslar juda kichik; qism so‘zlardan so‘z vektorini hosil qilish operatori asoslanmagan; dekodlash usullari va modelning turg‘unligi tizimli o‘rganilmagan. **Tadqiqot shu bo‘shliqni to‘ldiradi.**

4-slayd — Masalaning qo‘yilishi

[2:25 → 3:35]

[Ko‘rsating: daraxt]

Gap — so‘zlar ketma-ketligi. Har bir so‘zga bitta **hokim so‘z** va munosabat turi mos qo‘yiladi. Masalan, «beradi» — gapning markazi, «asarlar» — uning egasi, «bizga» — vositali to‘ldiruvchi.

Birinchi ta’rif: bog‘liqlik daraxti — bu ildizi sun’iy ROOT uchida bo‘lgan yoyiluvchi yo‘naltirilgan daraxt, ya’ni **arborestsensiya**.

Lemma: n ta so‘zli gap uchun bunday daraxtlar soni n ning n minus birinchi darajasiga teng. Bu Cayley formulasidan kelib chiqadi. O‘n so‘zli gap uchun — bir milliard daraxt. Demak, barcha variantlarni saralab chiqish mumkin emas.

[Ko‘rsating: qizil blok]

Shuning uchun masala ikki qismga bo‘linadi: **dekodlash** — eng ehtimolli daraxtni topish va **o‘qitish** — empirik riskni minimallashtirish. Sifat UAS va LAS mezonlari bilan baholanadi.

5-slayd — Maqsad, vazifalar, obyekt va predmet

[3:35 → 4:15]

Tadqiqotning maqsadi — kam resursli sharoitda o‘zbek tili gaplarini tahlil qilishning **matematik modelini, sonli usullarini va dasturiy maj-**

muasini yaratish.

Buning uchun beshta vazifa qo‘yildi: korpus yaratish; masalani formallashtirish; birlashtirish operatorini ishlab chiqish; o‘qitish va dekodlash usullarini tadqiq qilish; aniqlik va turg‘unlikni baholab, dasturiy majmuani yaratish.

Obyekt — o‘zbek tilidagi matnlar va korpuslar; predmet — tahlilning graf-ehtimollik modeli va sonli usullari.

6-slayd — Ilmiy yangilik

[4:15 → 5:00]

Tadqiqotning **to‘rtta** ilmiy yangiligi bor.

Birinchidan, o‘zbek tili uchun oltin standart UzUDT korpusi yaratildi va xalqaro UD tizimida e’lon qilindi.

Ikkinchidan, masala arborestsensiyalar ustida formallashtirildi va «oxirgi qism so‘z» operatori taklif etildi; uning ustunligi statistik tasdiqlandi.

Uchinchidan, o‘qitish va aniq dekodlashning sonli sxemasi ishlab chiqildi, modelning turg‘unligi baholandi.

To‘rtinchidan, dasturiy majmua yaratildi.

Har bir slayd qaysi yangilikka tegishli ekani pastki o‘ng burchakda ko‘rsatilgan.

7-slayd — Matematik modelning umumiy sxemasi

[5:00 → 5:40]

Model ikki qismdan iborat.

[Ko‘rsating: yuqori qator]

Birinchi qism — **kontekstli tasvir**: gap qism so‘zlarga bo‘linadi, TahrirchiBERT har biriga vektor beradi, so‘ng bu vektorlar so‘z darajasiga birlashtiriladi.

[Ko‘rsating: pastki qator]

Ikkinchi qism — **tuzilmani baholash**: BiLSTM kontekstni hisobga oladi, bi-affin funksiya har bir so‘z juftligini baholaydi va Chu–Liu–Edmonds algoritmi daraxtni topadi. Keyingi slaydlarda har bir blokning formulalari.

8-slayd — Qism so‘zlarni birlashtirish operatori

[5:40 → 6:40]

BERT so‘zni bir nechta qism so‘zga bo‘ladi, bizga esa har bir so‘z uchun bitta vektor kerak. Buni Π **matritsa** bilan yozamiz: so‘z vektori — qism so‘z vektorlarining qavariq kombinatsiyasi, Π — qator-stoxastik matritsa.

Ikki variant bor: **o‘rtacha qiymat** — barcha bo‘laklarga teng vazn; va biz taklif qilgan **«oxirgi qism so‘z»** — butun vazn oxirgi bo‘lakka beriladi.

[Ko‘rsating: jadval]

Jadvalda TahrirchiBERT tokenizatorining haqiqiy natijalari. Har safar oxirgi bo‘lakda kelishik yoki shaxs-son qo‘shimchasi turibdi: «dagi», «ning», «misiz».

Gipotezamiz: o‘zbek tilida grammatik ma’lumot so‘zning o‘ng chetida to‘planadi, o‘rtacha qiymat esa uni suyultiradi.

9-slayd — Kodlovchi: highway BiLSTM

[6:40 → 7:20]

Kirish vektori oltita qismdan iborat: so‘z, lemma, teglar, morfologik belgilar, harf darajasidagi vektor va BERT vektori — jami bir ming bir yuz qirq uch o‘lcham.

Kodlovchi — **LSTM**. Formulalari slaydda: uchta darvoza va xotira holati. Unutish darvozasi gradientning so‘nishini yumshatadi, shuning uchun uzoq bog‘lanishlar saqlanadi. Biz uch qatlamli, ikki yo‘nalishli variantdan foydalandik.

10-slayd — Chuqur bi-affin baholash

[7:20 → 8:25]

Endi asosiy blok. Har bir so‘z ikki rolda tasvirlanadi: **tobe** so‘z va **hokim** so‘z sifatida. Juftlik bahosi — kengaytirilgan vektorlardagi **bilinear forma**.

Ikkinchi lemma: U matritsani bloklarga ajratsak, bahoning bir qismi j ga bog‘liq emas. Softmax siljishga invariant, shuning uchun bu had ehtimollikka ta’sir qilmaydi. Qolgan had — so‘zning hokim bo‘lishga moyilligi.

Bahoga yana ikki had qo‘shiladi: yoy yo‘nalishi va masofa. Masofa uchun **Koshi yadrosi** ishlatiladi.

[Ko‘rsating: grafik]

Grafik buni asoslaydi: yoylarning yarmidan ko‘pi qo‘shni so‘zlar orasida, lekin uzun yoylar ham uchraydi — taqsimot og‘ir dumli. Yoylarning **sakson to‘rt foizida** hokim so‘z o‘ngda — bu o‘zbek tilining SOV tartibi.

11-slayd — Sonli usul (1): Chu–Liu–Edmonds

[8:25 → 9:25]

Har bir yoyga ehtimollik logarifmi og‘irlik sifatida beriladi.

Teorema: model yoylar bo‘yicha faktorlansa, eng ehtimolli daraxt — **maksimal og‘irlikdagi yoyiluvchi arborestsensiya**. Chu–Liu–Edmonds algoritmi uni aniq topadi; murakkabligi — n kub, Tarjan amalga oshirishida — n kvadrat.

[Ko‘rsating: sxema]

Algoritm g‘oyasi: har bir so‘z uchun eng yaxshi hokimni tanlaymiz. Sikl hosil bo‘lsa, uni bitta uchga qisqartiramiz va masalani qayta yechamiz.

[Ko‘rsating: jadval]

Yigirma so‘zli gap uchun daraxtlar soni o‘n ning yigirma to‘rtinchi darajasida, algoritm esa taxminan to‘rt yuz amal bajaradi. Muhim fakt: korpusdagi gaplarning **to‘qqiz foizi noproyektiv**; proyektiv usullar bunday daraxtlarni qura olmaydi.

12-slayd — Sonli usul (2): o‘qitish

[9:25 → 10:20]

Yo‘qotish funksiyasi — hokim va munosabat ehtimolliklarining manfiy logarifmi. Ikki korpus birlashtirilganda empirik risk ikkita riskning **qavariq kombinatsiyasiga** aylanadi; lambda — birinchi korpusning ulushi.

Minimallashtirish uchun **Adam** usulidan foydalandik. Uch ming qadam davomida yaxshilanish bo‘lmasa, AMSGrad variantiga o‘tamiz, yana uch ming qadamdan keyin to‘xtatamiz.

[Ko‘rsating: grafik]

O‘qitish egri chiziqlari jurnallardan olingan. Eng yaxshi natija **sakkiz yuz — bir ming uch yuz** qadamda erishiladi, keyin model haddan tashqari moslasha boshlaydi. Shuning uchun erta to‘xtatish zarur.

13-slayd — Ma’lumotlar va tajriba dizayni

[10:20 → 11:00]

Tajribalar ikki korpusda o‘tkazildi. **UzUDT** — men yaratgan korpus: olti yuz sakson to‘rt gap, olti annotator, kelishuv to‘qson foizdan yuqori. **UT** —

yangiliklar va badiiy matnlar.

[Ko‘rsating: grafik]

Korpuslar bir-birini to‘ldiradi: UzUDT da ravishdosh qurilmalari ko‘p, UT da — atoqli otlar va yordamchi fe’lli birikmalar.

Tajriba rejasi — uchta vektor turi va ikkita ma’lumot sharoitidan iborat faktorli dizayn.

14-slayd — Natijalar

[11:00 → 12:10]

Jadvalda validatsiya to‘plamidagi natijalar — e’lon qilingan modellarning eng yaxshi nazorat nuqtasi.

[Ko‘rsating: A blok]

A blokda barcha modellar bir xil sharoitda. TahrirchiBERT va oxirgi qism so‘z operatori eng yaxshi natija berdi: LAS — **ellik sakkiz butun yigirma uch**.

Farq tasodifiy emasmi? Buni **juftlashgan bootstrap** usuli bilan tekshirdik: gaplar o‘n ming marta qayta tanlandi.

[Ko‘rsating: bootstrap bloki]

Oxirgi qism so‘z operatorining ustunligi **statistik ahamiyatli**: ishonch oralig‘i noldan katta, p taxminan nol butun mingdan ikki.

B blokda — ikki korpus birlashmasi. Bu yerda parserga oltin morfologik teglar berilgan, shuning uchun A va B ni bevosita taqqoslamaymiz. Eng

yuqori LAS — oltmish uch butun sakson bir. Qiziq natija: morfologiya ma'lum bo‘lsa, BERT ning sintaktik ustunligi yo‘qoladi.

15-slayd — Test to‘plami: turg‘unlik va dekodlash usullari

[12:10 → 13:05]

[Ko‘rsating: o‘ng jadval]

Bir xil test to‘plamida ikki yondashuvni solishtirdik: aniq MST dekodlashli graf modeli va ochko‘z o‘tish modeli. Farq — LAS bo‘yicha **sakkiz butun yetti punkt**. Sababi: ochko‘z usulda bitta xato keyingi qarorlarga tarqaladi, global optimallashtirishda esa bunday bo‘lmaydi.

[Ko‘rsating: grafik]

Turg‘unlikni baholash uchun **g‘alayon operatorlarini** kiritdik. Diakritik belgilar olib tashlansa, LAS atigi bir punkt kamayadi; rus tilidagi so‘zlarga model deyarli befarq. Tinish belgilari olib tashlansa esa, LAS sakkiz punktdan ko‘proq tushadi. Demak, tinish belgilari — muhim tuzilmaviy signal.

16-slayd — Dasturiy majmua

[13:05 → 13:40]

Barcha usullar dasturiy majmuada amalga oshirildi. U to‘rt qismdan iborat: ma'lumotlarni tayyorlash; o‘qitish — Stanza kutubxonasiga BERT

ni ulaydigan yangi parametrlar va spaCy uchun o‘zbek tili moduli; baholash — metrikalar, bootstrap va turg‘unlik testlari; va e’lon qilish — korpus UD tizimida, modellar HuggingFace platformasida ochiq.

17-slayd — Xulosa

[13:40 → 14:35]

Xulosa qilib aytganda:

- o‘zbek tili uchun oltin standart **UzUDT** korpusi yaratildi;
- sintaktik tahlil masalasi **arborestsensiyalar ustidagi optimallashtirish** masalasi sifatida qo‘yildi;
- **«oxirgi qism so‘z»** operatori kiritildi va uning ustunligi statistik tasdiqlandi;
- aniq Chu–Liu–Edmonds dekodlash ochko‘z usuldan **sakkiz butun yetti punkt** yuqori natija berdi;
- model orfografik g‘alayonlarga turg‘un, tinish belgilariga sezgir;
- dasturiy majmua yaratildi.

[pauza]

Kelgusida barcha tajribalarni **yagona test to‘plamida** qayta baholash, ko‘p urug‘li tajribalar va global normallashgan modelni tadqiq qilish rejalashtirilgan.

18-slayd — Aprobatsiya va nashrlar

[14:35 → 14:50]

Natijalar oltita ilmiy ishda e'lon qilingan, barchasi Scopus bazasida: *Data in Brief* jurnalida (Q1), NLDB (Springer, Q2), IEEE EDM (Q3), LREC 2026 va IEEE USBEREIT anjumanlarida.

19-slayd — E'tiboringiz uchun rahmat!

[14:50 → 15:00]

E'tiboringiz uchun rahmat! Savollaringizga javob berishga tayyorman.

Ehtimoliy savollar va qisqa javoblar

- *Nega har bir so‘z uchun alohida softmax (lokal normallash), global ehtimollik modeli emas?* — Lokal model o‘qitishni sodda va tez qiladi. Dekodlash baribir global: MST daraxt shartini kafolatlaydi. Global model uchun bo‘linish funksiyasi $Z(x)$ Kirchhoff matritsa-daraxt teoremasi bilan determinant orqali $O(n^3)$ da hisoblanadi — bu keyingi bosqich.

- *CLE algoritmi nega optimal?* — Asosiy lemma (Edmonds, 1967): ochko‘z tanlovdagi sikl C optimal daraxtda faqat bitta kiruvchi yoy bilan almashadi; qisqartirilgan grafdagi optimal daraxt asl grafdagi optimal daraxtga mos keladi. Har bir kontraksiya $O(n^2)$, ular ko‘pi bilan n ta $\Rightarrow O(n^3)$; Tarjan (1977) — $O(n^2)$.

- *Bitta ildiz sharti qanday hisobga olinadi?* — Stanza nomzod ildizlar bo‘yicha CLE ni qayta yechadi va eng katta og‘irlikli daraxtni tanlaydi. Bu masalaning nazariy tahlili: Gabow va Tarjan (1984), Zmigrod va b. (2020).

- *Nima uchun Koshi yadrosi, Gauss emas?* — Yoy uzunligi taqsimoti og‘ir dumli (3,3 % yoylar 10 dan uzun). Gauss yadrosi uzun yoylarni haddan tashqari jazolaydi, Koshi yadrosi esa $1/d^2$ tezlikda so‘nadi. Bu had Stanza modelidan (Qi va b., 2018) olingan.

- *Nima uchun $\frac{1}{4}$ koeffitsient uchta qatlam uchun?* — Bu Stanza kutubxonasining standart sozlamasi: 9–11-qatlamlar yig‘indisi 4 ga bo‘linadi. O‘zgarmas masshtab keyingi chiziqli qatlamda to‘liq kompensatsiya qilinadi, ya’ni model sinfi o‘zgarmaydi.

- *Nega BERT sozlanmagan (muzlatilgan)?* — 781 gapda 110 mln parametrni sozlash haddan tashqari moslashish xavfini oshiradi. Muzlatilgan model bilan o‘qitiladigan parametrlar kam, natija barqaror.

- *Natijalar nega validatsiya to‘plamida?* — Repozitoriy jurnallarida o‘qitish davomida validatsiya ko‘rsatkichlari saqlangan. Test to‘plamidagi baholash E2.1 va spaCy uchun bajarilgan (15-slayd); barcha modellarni yagona test to‘plamida qayta baholash — eng yaqin vazifa.

- *Statistik ahamiyatlilik qanday baholandi?* — Juftlashgan bootstrap: birlik — gap (xatolar gap ichida bog‘liq), $B = 10^4$, bir tomonlama $p = P^*(\Delta^* \leq 0)$. Bitta modelning LAS ishonch oralig‘i taxminan ± 5 punkt (48 gap), shuning uchun faqat juftlashgan taqqoslash ma’noli.

- *Korpuslarni birlashtirish qancha foyda beradi?* — Birlashma tajribalarida parserga oltin teglar berilgan va validatsiya to‘plamlari ham farqli. Shuning uchun sof ta’sirni ajratish uchun qo‘shimcha tajriba (bir xil teglar, umumiy test gaplari) rejalashtirilgan.

- *Nima uchun o‘tish modeli (spaCy) UPOS da yaxshi, LAS da yomon?* — spaCy transformerni teglash bilan birga sozlaydi, shuning uchun teglash yaxshi. Lekin ochko‘z ketma-ket qarorlar xatoni tarqatadi va global optimal yechim kafolatlanmaydi.

- *Katta til modellari (GPT va boshqalar) bilan taqqoslanganmi?* — Hozircha yo‘q; bu kelgusi ish. Til modelining javobida daraxt sharti kafolatlanmaydi, bizning yondashuvda esa MST orqali kafolatlanadi.

- *Mavzuda nega «semantik» tahlil yo‘q?* — Tadqiqot morfologik va sintaktik qatlamlarga qaratilgan. Sintaktik daraxt — semantik tahlil uchun

asos; semantik rollar annotatsiyasi — keyingi bosqich.

- *Amaliy qo‘llanilishi?* — Mashina tarjimasi, axborot qidirish, savol-javob tizimlari, grammatik tekshiruv va ta’lim matnlarini tahlil qilish.